Scoring de crédit explicable

Mohamed Aljene · II3-IF · Data Mining, ENSI · 2026-2027
Enseignante : Rym Besrour · Synthèse en une page

1. Le problème

Une banque veut repérer, un mois à l'avance, les clients de carte de crédit qui risquent de ne pas payer, et pouvoir **expliquer chaque décision** au client et au régulateur.

2. Les données

30 000 clients taïwanais (2005), 23 informations par client : plafond de crédit, profil, retards de paiement, factures et paiements des six derniers mois. **22,1 % ont fait défaut** le mois suivant. Les codes non documentés de deux variables ont été regroupés.

3. La méthode

Conformément à la consigne de l'enseignante, on compare deux modèles simples (régression logistique, arbre de décision) et deux modèles ensemblistes (Random Forest, XGBoost), réglés par GridSearchCV sur 80 % des clients (145 combinaisons de réglages testées par validation croisée). Le seuil de décision est choisi par validation croisée sur ces mêmes clients. Les 20 % restants (6 000 clients) ne servent qu'à la mesure finale.

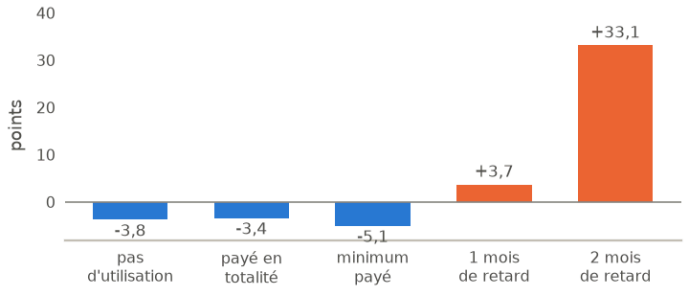
4. Les résultats

Modèle	AUC sur le test
XGBoost (référence)	**0,779 [0,765 ; 0,795]**
Random Forest	0,774
Arbre de décision	0,765
Régression logistique	0,710
XGBoost sans variables sensibles	**0,776 (seuil 0,279)**

L'AUC est la probabilité qu'un mauvais payeur reçoive une note plus élevée qu'un bon payeur (0,5 = hasard, 1 = parfait). Sur le test, XGBoost atteint aussi un Gini de 0,558 et un KS de 0,427. Au seuil retenu, sur 6 000 clients, XGBoost en signale **1 423** : **743** font réellement défaut (52 %) ; il manque 584 défauts sur 1 327. Ses probabilités sont fiables : parmi les clients notés environ 40 %, environ 40 % font réellement défaut.

5. Ce qui explique le risque

Le retard de paiement du dernier mois pèse plus que tout le reste. Le risque reste bas tant que le client paie au moins le minimum, puis bondit dès un mois de retard ; à deux mois, la note augmente de **33 points** en moyenne. Un plafond de crédit faible augmente aussi le risque.



Effet moyen du statut de paiement du dernier mois sur la note (SHAP, XGBoost, 1 000 clients).

Exemple, client 1358 :

> *« Le risque de défaut est élevé (71 % contre 22 % en moyenne), principalement à cause d'un retard de paiement de 2 mois en septembre et en août et d'un plafond de crédit faible (20 000 NT$). »*

6. Analyse critique

SHAP et LIME sont-ils d'accord ? Pour l'essentiel, oui : sur 20 clients, ils partagent en moyenne 3,8 variables sur les 5 principales, et vont dans le même sens dans 72 cas sur 75. Ils retrouvent l'intuition d'un banquier : retards récents et plafond faible. Limite : LIME change un peu d'un tirage à l'autre pour certains clients ; SHAP sert donc de référence.

Le modèle s'appuie-t-il sur des variables sensibles ? Peu. Le sexe, l'âge, la situation familiale et le niveau d'études pèsent peu, et les autres variables ne permettent guère de les deviner. En revanche, un bon payeur homme est plus souvent signalé à tort qu'une bonne payeuse (17,4 % contre 12,7 %), de même que les moins de 26 ans (21,2 %) et les plus de 55 ans (22,7 %). Comme ces groupes font un peu plus souvent défaut, un modèle qui donne un risque juste à chaque groupe ne peut pas avoir en même temps le même taux de fausses alertes pour tous : la banque doit choisir lequel de ces deux objectifs elle privilégie. Retirer les quatre variables sensibles ne coûte que 0,002 d'AUC.

Performance ou simplicité ? La régression logistique, la plus simple à expliquer, perd 0,069 d'AUC : elle ne sait pas représenter le bond du risque au premier mois de retard. Un arbre de trois questions, lisible en entier, perd 0,052 (en validation croisée). XGBoost, expliqué par SHAP, donne à la fois la meilleure performance et une explication pour chaque client.

Quelles actions pour le décideur ?

- Agir dès le **premier mois de retard** : relance, échéancier, conseil.
- Réexaminer les clients à plafond faible qui commencent à payer en retard.
- Fixer le seuil selon le coût réel d'un défaut manqué face à celui d'un bon client refusé.
- Remettre au client la phrase qui explique sa note, et lui dire ce qui la ferait baisser.

> **Recommandation.** Déployer **XGBoost sans variables sensibles** (AUC test 0,776, seuil 0,279), déjà servi par l'API du projet. Suivre chaque trimestre sa performance et les écarts d'erreur entre groupes, et le réentraîner sur des données récentes.

7. Limites

- Données de Taïwan en 2005 : les comportements actuels peuvent être différents.
- Le codage des retards semble varier selon le mois (« 1 mois de retard » n'apparaît presque qu'en septembre).
- 795 comptes sans aucune facture ni aucun paiement font pourtant défaut à 37,6 % : la définition du défaut est peut-être bruitée.
- Le jeu ne donne pas le coût des erreurs : le seuil est choisi sur un équilibre précision / rappel (F1).
- Le modèle sans variables sensibles reprend les réglages du modèle complet, sans réglage dédié.

Données : Default of Credit Card Clients, UCI (id 350), licence CC BY 4.0 ; Yeh et Lien (2009).
API : https://credit-scoring-xai-api.onrender.com (documentation : /docs)
Code, notebook, journal des décisions : https://github.com/aljene307/credit-scoring-xai